

Travel Time Prediction for Bus Segments Using Historical GPS Data

[Tes Teknikal] AI/ML – Bernand Trianda Firmansyah

1. Exploratory Data Analysis (EDA)

Dataset terdiri dari **351.103 observasi** dan tidak ditemukan missing value.

Distribusi `traveling_time_sec` sangat right-skewed dengan nilai maksimum melebihi 900.000 detik yang mengindikasikan kemacetan ekstrem, insiden operasional, atau anomali pencatatan. Untuk menstabilkan distribusi digunakan transformasi:

```
log1p(traveling_time_sec)
```

Analisis trip incompleteness dilakukan menggunakan selisih antar `stop_sequence`. Gap didefinisikan ketika:

```
seq_diff > 1
```

Hasilnya, hanya ditemukan 3 observasi gap (<0.001%), sehingga data tidak dihapus dan hanya ditambahkan fitur `is_gap_suspected`.

Selain itu, ditemukan sparsity pada beberapa segmen yang memiliki jumlah observasi historis rendah. Untuk mengurangi risiko overfitting, dibuat fitur `segment_frequency`.

2. Feature Engineering

Fitur tambahan yang digunakan meliputi:

- `hour`
- `day_of_week`
- `is_weekend`
- `is_peak_hour`
- `prev_travel_time`
- `rolling_mean_3`
- `segment_frequency`
- `is_gap_suspected`

Fitur `prev_travel_time` dan `rolling_mean_3` digunakan untuk menangkap dependency antarsegmen dalam satu trip.

3. Model Development

Model baseline yang digunakan adalah XGBoost Regressor karena mampu menangani hubungan nonlinier, robust terhadap outlier, dan efektif untuk data tabular.

Target ditransformasikan menggunakan:

```
y_log = log1p(traveling_time_sec)
```

Untuk mengurangi pengaruh outlier selama training.

4. Evaluation Result

Segment-Level Performance

Metric	Result
MAE	221.93 sec
RMSE	6033.10 sec
MAPE	28.04%

Trip-Level Performance

Metric	Result
Trip MAE	786249.27 sec

Feature paling berpengaruh adalah:

1. average_time_sec
2. rolling_mean_3
3. prev_travel_time

Hal ini menunjukkan bahwa informasi historis dan pola sekuensial memiliki kontribusi terbesar terhadap prediksi travel time.

5. Recommendation: Ensemble LSTM + XGBoost

XGBoost efektif untuk memanfaatkan fitur tabular seperti route, segment, jam operasional, dan historical average, sedangkan LSTM mampu menangkap dependency antarsegmen dalam satu trip.

Strategi ensemble yang direkomendasikan:

$$\text{Final Prediction} = 0.7 \times \text{XGBoost} + 0.3 \times \text{LSTM}$$

Pendekatan ini diperkirakan memberikan performa lebih baik dibandingkan dengan model tunggal pada data operasional transportasi yang memiliki karakteristik sekuensial.

6. Conclusion

Kualitas data secara umum baik karena tidak ditemukan missing value dan hanya terdapat tiga kasus trip incompleteness. Distribusi target yang sangat skewed berhasil ditangani menggunakan log transformation.

Model baseline XGBoost menghasilkan **MAE 221.93 detik**, **RMSE 6033.10 detik**, dan **MAPE 28.04%**. Untuk implementasi produksi, kombinasi LSTM dan XGBoost direkomendasikan karena mampu menggabungkan informasi tabular dan sekuensial secara lebih efektif.